






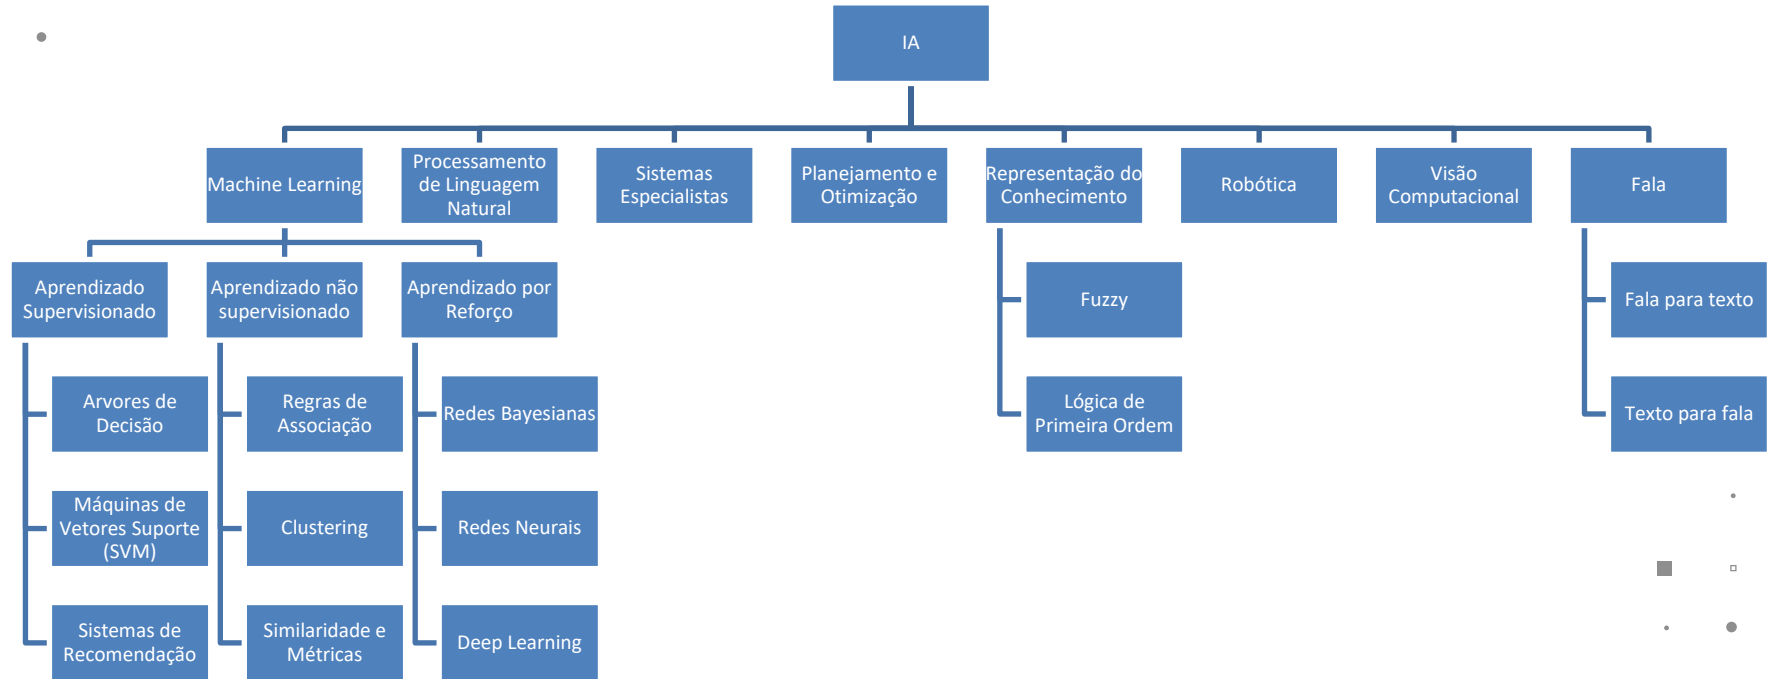
FIAP



# Introdução




# Principais Áreas da IA




# Programação Tradicional vs IA


## Traditional Programming



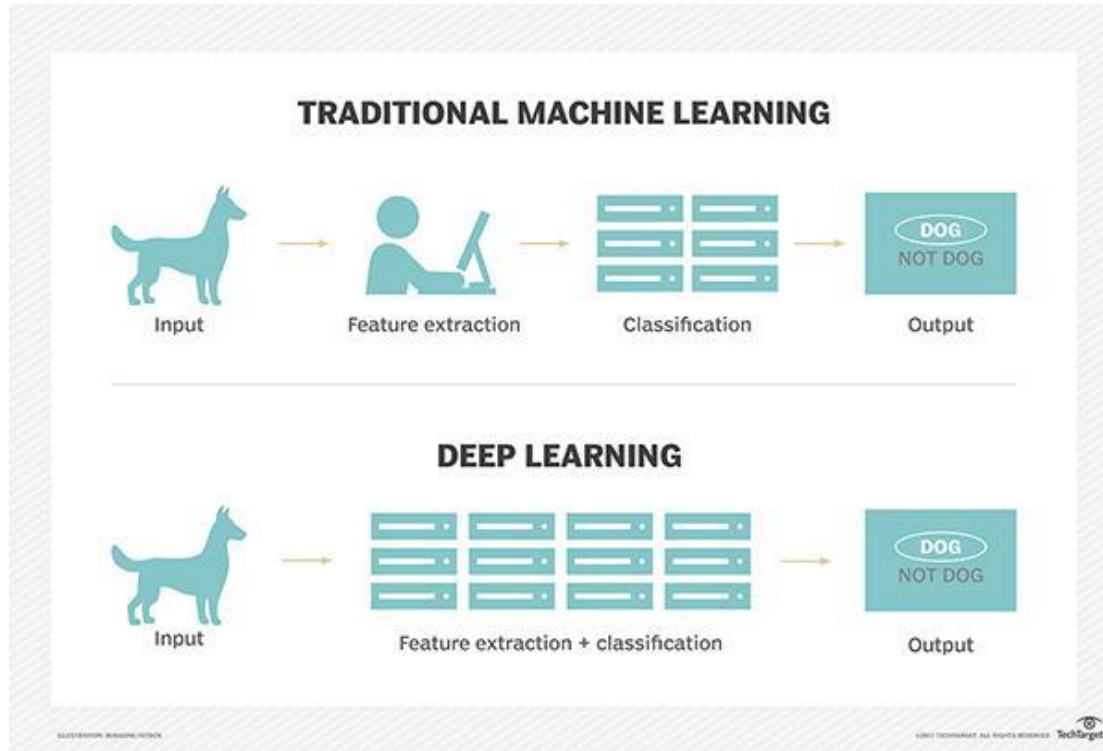
## Machine Learning



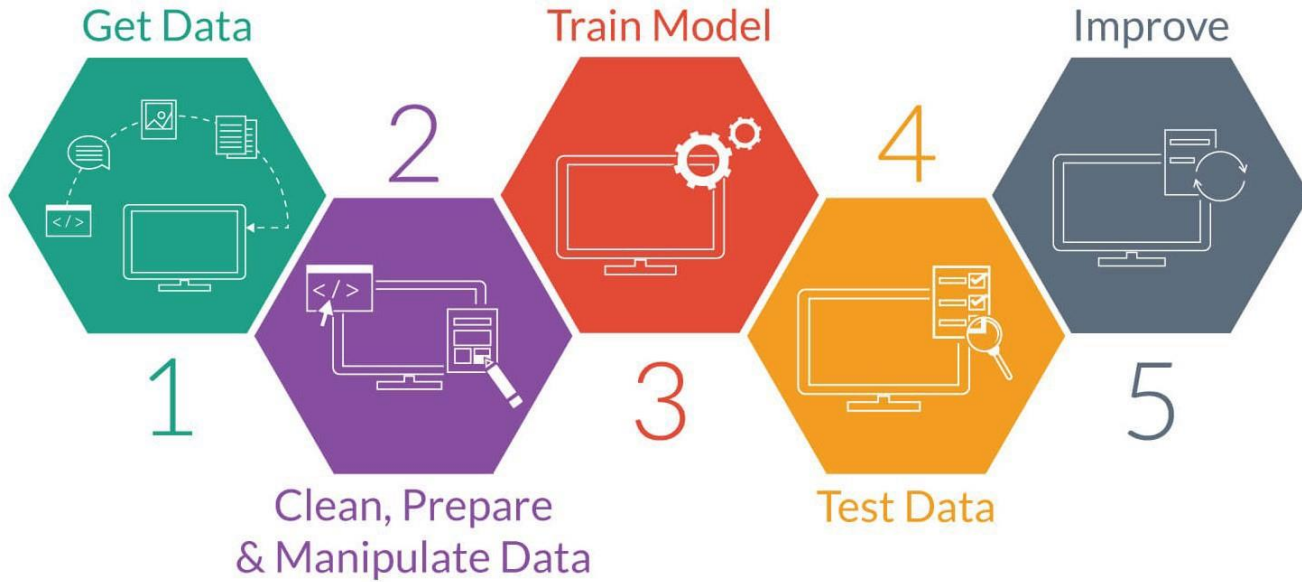
# Machine e Deep Learning



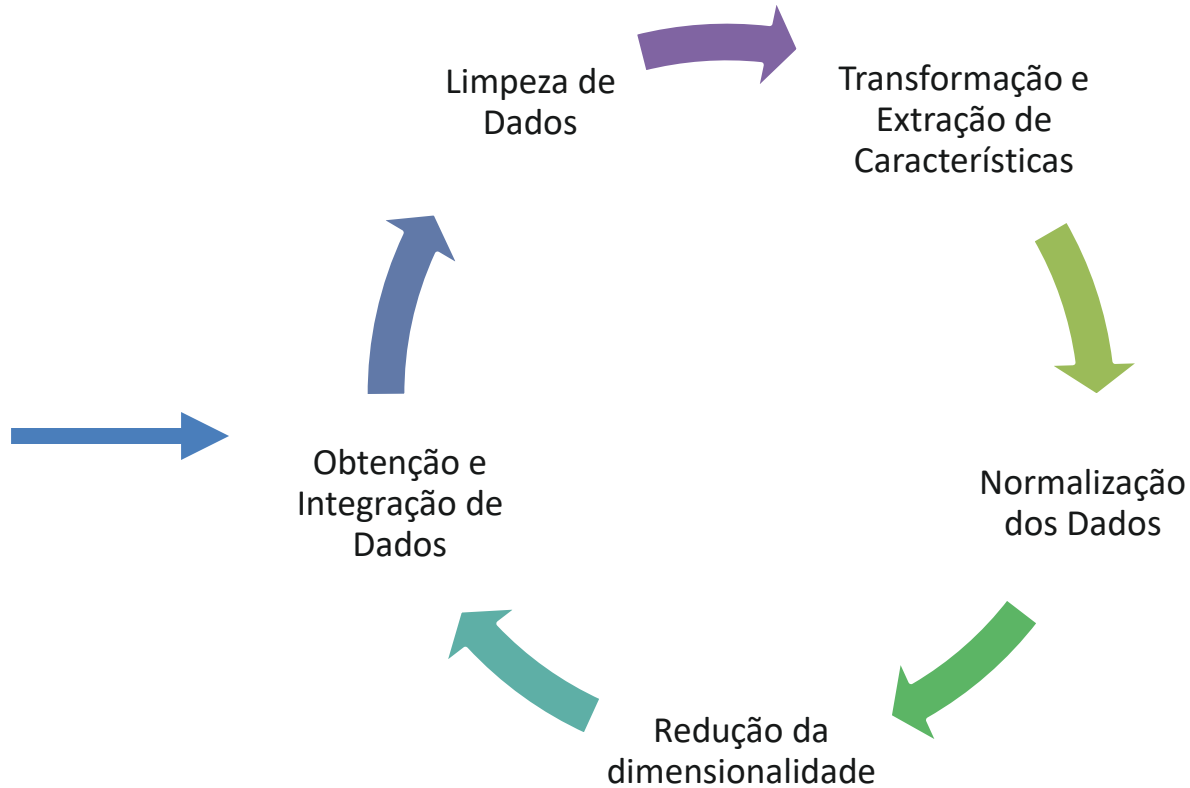
# Machine e Deep Learning



## Modelos de IA



# Pré-Processamento dos Dados





## Pré-Processamento dos Dados

### Normalização

Transformar um conjunto de dados que estão em diferentes grandezas e escalas em um conjunto de dados padronizados.


### Normalization Formula

$$X_{normalized} = \frac{(X - X_{minimum})}{(X_{maximum} - X_{minimum})}$$



## Extração de Características

Como extrair características de uma impressão digital?



## Extração de Características

Como extrair características de uma Face para reconhecimento Facial?

Demonstração

# Tipo de Aprendizado e Problemas da IA



## Tipos de Problema de ML e IA



**Clusterização:** tenta agrupar os dados mais semelhantes entre si.



# Tipos de Problema de ML e IA

## Clusterização – Algoritmo K-means:

K Means Clustering


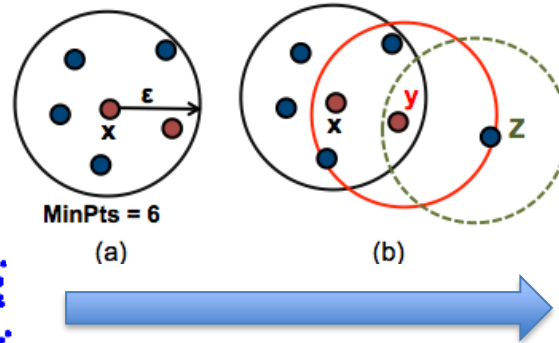


## Tipos de Problema de ML e IA

Clusterização – Algoritmo DBSCAN:



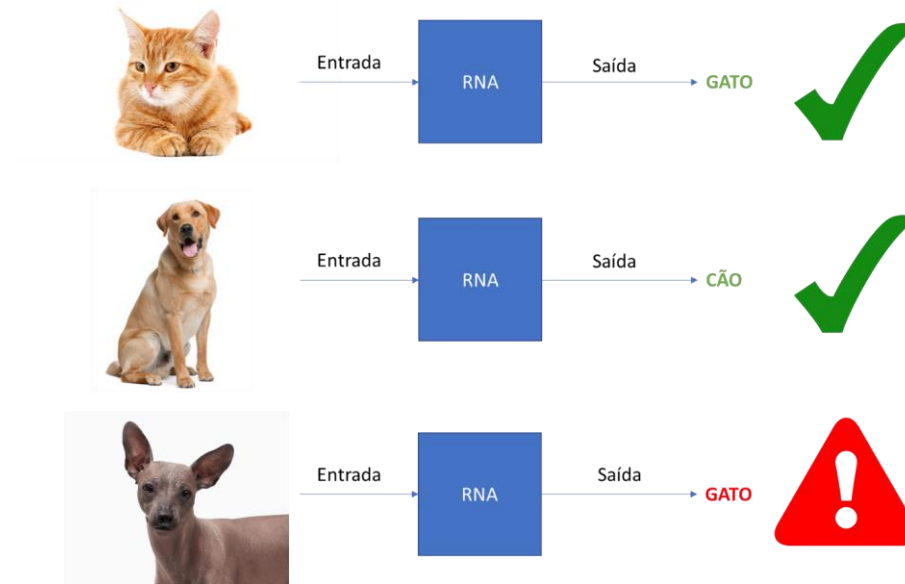
Pontos Originais



Clusters

## Tipos de Problema de ML e IA

**Classificação Binária:** tenta prever uma resposta simples, ex: sim ou não, cão ou gato



**RNA – Rede Neural Artificial**



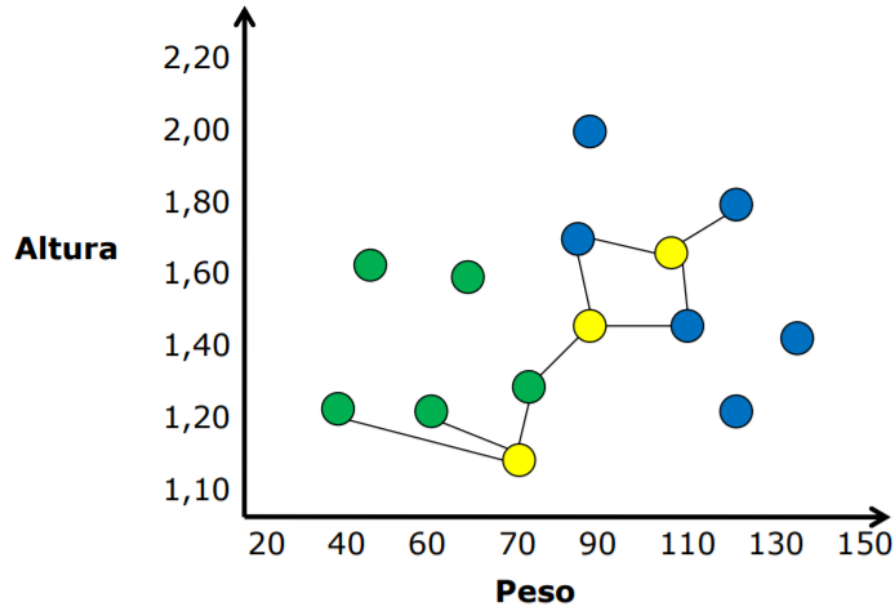
## Tipos de Problema de ML e IA

**Classificação Multiclasse:** tenta colocar um exemplo em uma das diversas classes do problema.



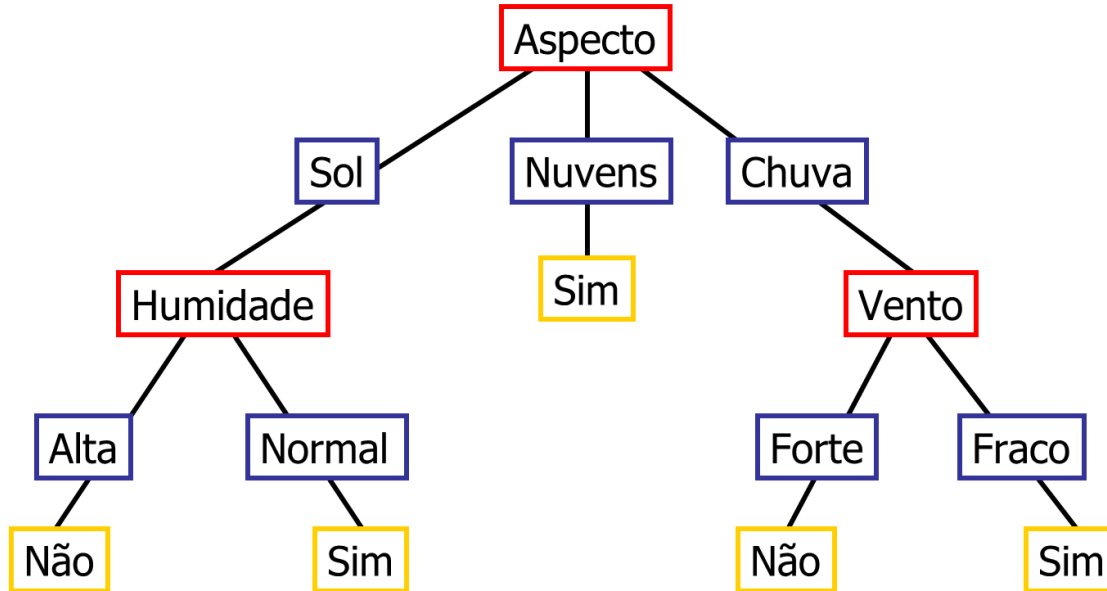
# Tipos de Problema de ML e IA

## Classificação – K-Nearest Neighbors




# Tipos de Problema de ML e IA

## Classificação - Árvores de Decisão:



# Tipos de Problema de ML e IA

## Classificação - Support Vector Machines:




## Tipos de Problema de ML e IA

Regressão: Tenta prever um valor real.





# Tipos de Problema de ML e IA

## Regressão – Regressão Linear:




# Tipos de Problema de ML e IA

## Regressão – Regressão Polinomial:



# Tipos de Problema de ML e IA

## Regressão – Árvores de Decisão para Regressão:






# Tipos de Problema de ML e IA

## Descoberta de Conhecimento



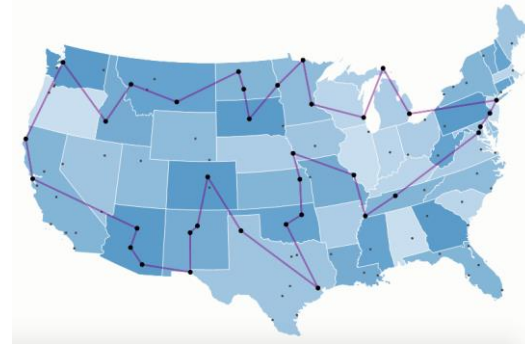

# Tipos de Problema de ML e IA

## Descoberta de Conhecimento



# Tipos de Problema de ML e IA

## Otimização



## Sistemas de Recomendação

You**Tube**

**NETFLIX**




udemy


amazon.com<sup>®</sup>

# Sistemas de Recomendação Simples

## COLLABORATIVE FILTERING




## CONTENT-BASED FILTERING

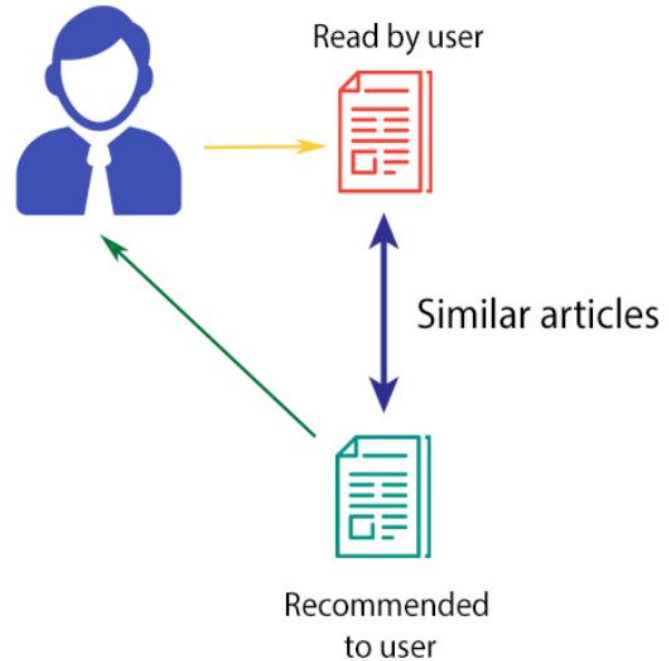


# Sistemas de Recomendação Simples

## COLLABORATIVE FILTERING



## CONTENT-BASED FILTERING



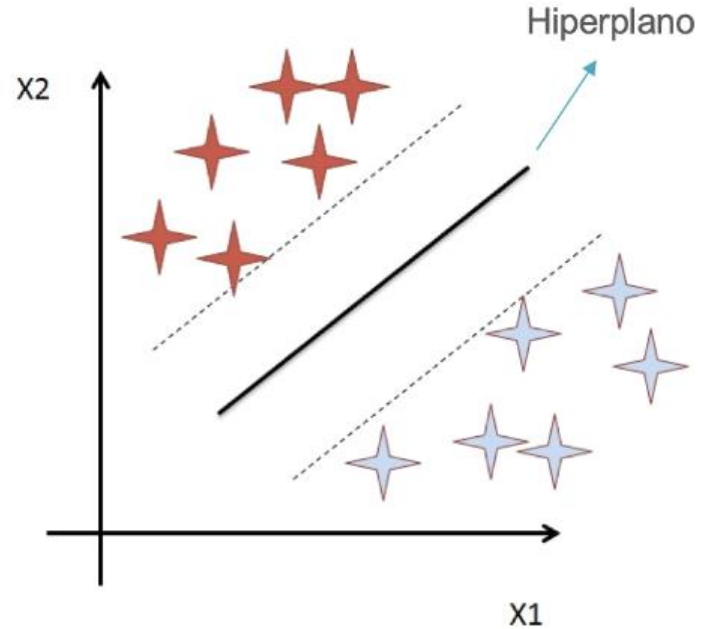
# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Support Vector Machines




Vladimir Vapnik - 1963





# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Support Vector Machines

## Algumas características das SVM's:

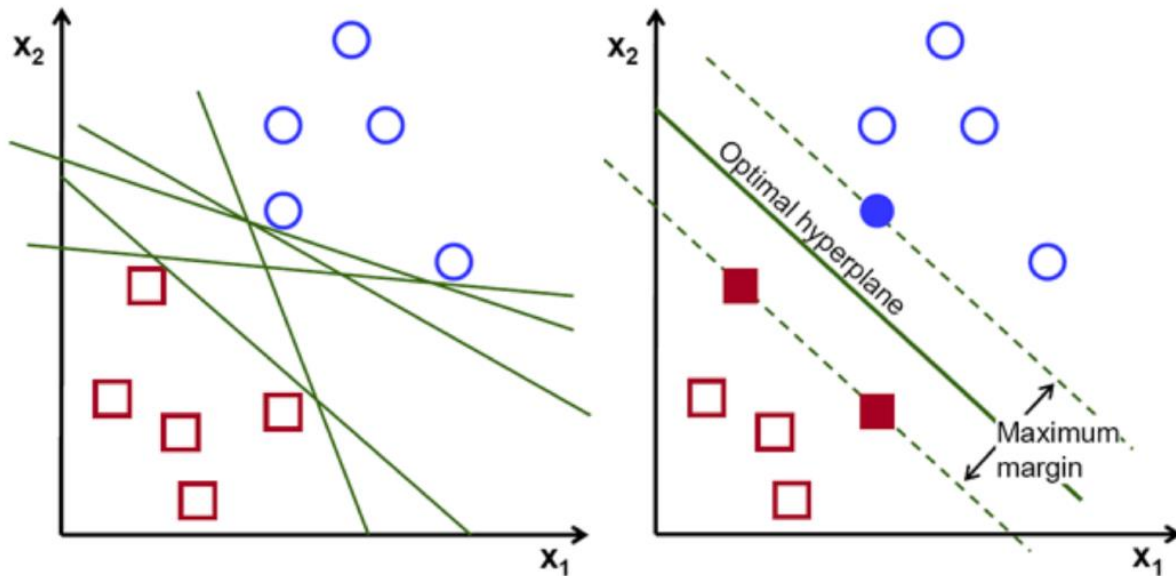
- Em caso de outliers o modelo SVM busca a melhor forma possível de classificação e, se necessário, desconsidera o outlier;
- É um classificador criado para fornecer separação linear;
- Funciona muito bem em domínios complicados, em que existe uma clara margem de separação;
- Não funciona bem em conjuntos de dados muito grandes, pois o tempo de treinamento é muito custoso;
- Não funciona bem em conjuntos de dados com grande quantidade de ruídos;
- Se as classes estiverem muito sobrepostas deve-se utilizar apenas evidências independentes.

# Machine Learning – SVM Support Vector

## Máquinas

O objetivo do algoritmo da máquina de vetores de suporte (SVM – Support Vector Machine) é encontrar um hiperplano em um espaço N-dimensional (N - o número de recursos ou atributos) que classifica distintamente os pontos de dados.

O Que São  
Vetores de  
Suporte?




# Machine Learning – SVM Support Vector Machines

Para separar as duas classes de pontos de dados, existem muitos hiperplanos possíveis que podem ser escolhidos. Nosso objetivo é encontrar um hyperplano com a margem máxima, ou seja, a distância máxima entre os pontos de dados das duas classes. A maximização da distância da margem fornece um limite para que os pontos de dados futuros possam ser classificados com mais confiança.


Hiperplanos são limites de decisão que ajudam a classificar os pontos de dados. A dimensão do hiperplano depende do número de recursos. Se o número de recursos de entrada for 2, o hiperplano será apenas uma linha. Se o número de recursos de entrada for 3, o hiperplano se tornará um plano bidimensional. Torna-se difícil imaginar quando o número de recursos excede 3.

# Machine Learning – SVM Support Vector Machines

A hyperplane in  $\mathbb{R}^2$  is a line




A hyperplane in  $\mathbb{R}^3$  is a plane



# Machine Learning – SVM Support Vector Machines

Os vetores de suporte são pontos de dados que estão mais próximos do hiperplano e influenciam a posição e a orientação do hiperplano. Usando esses vetores de suporte, maximizamos a margem do classificador. A exclusão dos vetores de suporte alterará a posição do hiperplano. Esses são os pontos que nos ajudam a criar nosso modelo SVM.



# Machine Learning – SVM Support Vector Machines


Support Vector Machines (SVM's) são modelos de aprendizagem supervisionada, que possuem algoritmos de aprendizagem que analisam dados e reconhecem padrões, utilizados para classificação e análise de regressão.

# Machine Learning – SVM Suport Vector Machines

Funcionamento do Modelo SVM para dados linearmente separáveis.




# Machine Learning – SVM Support Vector Machines





Dados Não Linearmente  
Separáveis

Dados Linearmente  
Separáveis


# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Support Vector Machines




Dados Não Linearmente  
Separáveis

Dados Linearmente  
Separáveis

Precisamos de Função de  
Kernel Para a Separação

# Machine Learning – SVM Support Vector Machines

Uma Dose de Matemática




Encontrar o valor de  $y$ :

$$y^{(i)} = \begin{cases} -1 & \text{if } \mathbf{w}^T \mathbf{x}^{(i)} + b \leq -1 \\ 1 & \text{if } \mathbf{w}^T \mathbf{x}^{(i)} + b \geq 1 \end{cases}$$

Distância Mínima Entre os VS:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$

# Machine Learning – SVM Support Vector Machines




**Distância Mínima Entre os VS:**

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$

**Maximizar a Distância Mínima  
(Otimização):**

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha^{(i)} - \sum_{i=1}^N \sum_{j=1}^N \left( y^{(i)} \alpha^{(i)} \phi(\mathbf{x}^{(i)})^T \phi(\mathbf{x}^{(j)}) y^{(j)} \alpha^{(j)} \right) \\ \text{s. t.} \quad & 0 \leq \alpha^{(i)} \leq C, \end{aligned}$$

# Machine Learning – SVM Support Vector Machines



**Maximizar a Distância Mínima  
(Otimização):**

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha^{(i)} - \sum_{i=1}^N \sum_{j=1}^N \left( y^{(i)} \alpha^{(i)} \phi(\mathbf{x}^{(i)})^T \phi(\mathbf{x}^{(j)}) y^{(j)} \alpha^{(j)} \right) \\ \text{s. t.} \quad & 0 \leq \alpha^{(i)} \leq C, \end{aligned}$$

Inner Product  
O Kernel Trick é este mapeamento.

Coeficiente aprendido durante o treinamento, um para  $i$  e outro para  $j$ .

# Machine Learning – SVM Suport Vector Machines

O produto escalar entre dois vetores (dot product) mostra como os vetores são "semelhantes". Se os vetores representam pontos no seu conjunto de dados, o produto escalar informa se eles são semelhantes ou não.

Mas, em alguns (muitos) casos, o produto escalar não é a melhor métrica de similaridade.


Por exemplo:

Talvez os pontos com produto escalar baixo sejam semelhantes por outras razões. Você pode ter itens de dados que não estão bem representados como pontos ou pode não haver separação linear.

Então, em vez de usar o produto escalar, você usa um "kernel", que é apenas uma função que recebe dois pontos e fornece uma medida de sua similaridade. O SVM aplica esse conceito que é denominado Truque do Kernel (Kernel Trick).



# Machine Learning – SVM Support Vector Machines





**Previsões do Modelo:**

$$\begin{aligned} y^{\text{test}} &= \text{sign}(\mathbf{w}^T \phi(\mathbf{x}^{\text{test}}) + b) \\ &= \text{sign}\left(\sum_{i=1}^N \alpha^{(i)} y^{(i)} \phi(x^{(i)})^T \phi(\mathbf{x}^{\text{test}}) + b\right) \end{aligned}$$

# Machine Learning – SVM Support Vector Machines


Funcionamento do Modelo SVM para dados NÃO linearmente separáveis.

# Machine Learning – SVM Support Vector Machines




# Machine Learning – SVM Support Vector Machines



Data in  $R^3$  (separable w/ hyperplane)



# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Suport Vector Machines

SVM's com Margens Rígidas

X


SVM's com Margens Flexíveis

# Machine Learning – SVM Support Vector Machines

As máquinas de vetores de suporte (chamadas SVMs) são um algoritmo de aprendizado supervisionado que pode ser usado para problemas de classificação e regressão como classificação de vetores de suporte (SVC) e regressão de vetores de suporte (SVR).



# Machine Learning – SVM Support Vector Machines





Os pontos mais próximos ao hiperplano são chamados de pontos do vetor de suporte e a distância dos vetores do hiperplano é chamada de margem.

A intuição básica a ser desenvolvida aqui é que quanto mais pontos SV adicionais, do hiperplano, maior a probabilidade de classificar corretamente os pontos em suas respectivas regiões ou classes. Os pontos SV são muito críticos na determinação do hiperplano porque se a posição dos vetores muda, a posição do hiperplano é alterada.



Tecnicamente, esse hiperplano também pode ser chamado de hiperplano de maximização de margem.

# Machine Learning – SVM Support Vector Machines



# Machine Learning – SVM Support Vector Machines

## Margens Rígidas



# Machine Learning – SVM Suport Vector Machines

## Margens Rígidas

Se os pontos são linearmente separáveis, apenas o nosso hiperplano é capaz de distinguir entre eles e se algum erro for introduzido (outliers por exemplo), não será possível separá-los.

Esse tipo de SVM é chamado SVM de Margem Rígida (já que temos restrições muito rígidas para classificar corretamente cada ponto de dados).

# Machine Learning – SVM Suport Vector Machines

## Margens Flexíveis

Basicamente, consideramos que os dados são linearmente separáveis e isso pode não ser o caso no cenário da vida real.

Precisamos de uma atualização para que nossa função possa pular alguns valores discrepantes e poder classificar pontos quase linearmente separáveis. Por esse motivo, apresentamos uma nova variável Slack ( $\xi$ ) chamada Xi.

### Distância Mínima Entre os VS:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$

# Machine Learning – SVM Suport Vector Machines

• Margens Flexíveis

Se  $\xi_i = 0$ , os pontos podem ser considerados corretamente classificados.  
Senão, se  $\xi_i > 0$ , pontos são classificados incorretamente.

Portanto, se  $\xi_i > 0$  significa que  $X_i$  (variáveis) está na dimensão incorreta, podemos pensar em  $\xi_i$  como um termo de erro associado a  $X_i$  (variável).

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

# Machine Learning – SVM Support Vector Machines


## Resumindo

A margem rígida é aquela que separa claramente os pontos positivos e negativos.

A margem flexível também é chamada SVM linear “barulhenta”, pois inclui alguns pontos classificados incorretamente.

# Machine Learning – SVM Support Vector Machines

Parâmetro de Regularização C



**Distância Mínima Entre os VS:**

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|^2}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$

**Maximizar a Distância Mínima (Otimização):**

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha^{(i)} - \sum_{i=1}^N \sum_{j=1}^N \left( y^{(i)} \alpha^{(i)} \phi(\mathbf{x}^{(i)})^T \phi(\mathbf{x}^{(j)}) y^{(j)} \alpha^{(j)} \right) \\ \text{s. t.} \quad & 0 \leq \alpha^{(i)} \leq C, \end{aligned}$$



# Machine Learning – SVM Support Vector Machines

## Parâmetro de Regularização C

O parâmetro de regularização C no Modelo SVM é responsável pelo treinamento do modelo com hiperplano de margem flexível ou rígida.

Quanto maior o valor de C menor a margem do hiperplano selecionada para o treinamento de um modelo.

Quanto menor o valor de C maior a margem do hiperplano escolhida para o treinamento de um modelo.

**Para obter resultados de classificação mais precisos (menos amostras classificadas incorretamente), é necessário selecionar C com grande valor.**

OBRIGADO

FIAP

Copyright © 2020 | Professora Felipe Gustavo Silva Teodoro

Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.



FIAP

